
LendingClub Defaulter Prediction




Business Understanding

- เป็นบริษัท Fintech ขนาดใหญ่
 ให้บริการเกี่ยวกับสินเชื่อ / กู้ยืมออนไลน์
- ไม่ผ่านตัวกลางอย่างสถาบันการเงิน
- เป็นการกู้ลักษณะ Peer-to-Peer Lending (P2P)
- มีการประเมินความเสี่ยงของผู้กู้
- มีรายได้จากค่าธรรมเนียมในการทำธุรกรรมแต่ละครั้ง

การกู้พ่านตัวกลางทางการเงินรูปแบบเดิม



การกู้เงินในรูปแบบ P2P Lending




Source: Fair Finance Thailand | Facebook



<u>ข้อง่าทัดครามรับผิด (Disclaimes)</u> บริการ Sham Loan by NESTIFLY ที่ใช่บริการของบริษัทแต่การัพย์ ปรหลาง จำกัด (มหาชน) ("BLS") แต่เป็นบริการของบริษัท แต่ที่ที่ต่าย จำกัด ทั้งนี้ BLS เป็นเพียงผู้เก็บริการของบริษัท และเป็นผู้สาก (ในกำหรับอาการของบริษัท แต่อยังค่ายองบริษัท สูนด์รับผ่าทเส่กหรัพย์ (ประเทศไทย) จำกัด ว่าตัวเการได้เล้าพรัพย์เป็นประทัน เท่านั้น แตกจากนี้ BLS มีใช่ผู้ให้ผู้กับ หรือผู้ก็อน รวมถึงไม่มี ความรับผิดใหญ่ ที่เก็บรูปของกับการให้บริการ Sham Loan by NESTIFLY แต่บริหาราจิโด

Source : Peer-to-Peer Lending (P2P) : ทางเลือกการขอสินเชื่อและการลงทุนรูปแบบใหม่ที่ สะดวก รวดเร็ว ไม่ต้องใช้สลิปเงินเดือน โดย Share Loan by NestiFly Bualuang Knowledge Sharing



NestiFly (blockdit.com)



Project Objectives

- ต้องการฝึกฝนและพัฒนาการทำความเข้าใจและ
 สำรวจข้อมูลด้วยมุมมองต่าง ๆ
- ต้องการเข้าใจวิธีการเตรียมข้อมูลในรูปแบบต่าง ๆ และวิธีการ Coding
- ต้องการฝึกฝน Coding ในการทำ Machine
 Learning และรู้จักกับ Model ใหม่ๆ ที่ไม่เคยศึกษา
- ต้องการ Case Study ที่เกี่ยวกับมุมมองการเงิน

Business Objectives

- ต้องการทำความเข้าใจตัวแปรหรือปัจจัยที่มีผลต่อการผิดนัด
 ชำระหนี้ด้วยการ Exploratory Data Analysis
- การให้กู้ยืมเงินเป็นการลงทุนที่มีความเสี่ยง ดังนั้นเมื่อเกิดการผิด นัดชำระหนี้ จะส่งผลเสียกับผู้ให้กู้หรือนักลงทุน หมายความว่า หากระบุ Defaulter ได้จะส่งผลให้ลดความสูญเสียในรูปตัวเงิน จากการผิดนัดชำระหนี้ได้ (Change-off / Default)
- ต้องการโมเดลที่ช่วยกรองผู้ที่มี "โอกาสผิดนัดชำระหนี้"
 เบื้องต้น เพื่อให้นักลงทุนใช้ในการพิจารณาเลือกผู้กู้ที่เหมาะสม
 แก่การลงทุนและยังช่วยลดความเสี่ยงได้ระดับนึง



PROJECT PROCESS

Ī

Exploratory Data Analysis

(Data Understanding)

2

Data **Preparation**

3

Modeling

4

Evaluation



PROJECT PROCESS

Data Preparation

I. Handling Numerical Variable

2. Handling Categorical Variable

- 3. Handling Missing Values
- 4. Drop Variables
- 5. Check for duplicate rows
- 6. Train Test Split
- 7. Outlier Handling for Train data
- 8. X_train y_train X_test y_test Split
- 9. Data Normalization (X_train, X_test)
- 10. Features Selection by LightGBM
- 11. Encoding (One Hot Encoding)

4

Exploratory Data Analysis

(Data Understanding)

* for target variable and features selected by LightGBM *

```
data.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 396030 entries, 0 to 396029
Data columns (total 27 columns):
# Column
                         Non-Null Count
                                         Dtype
                         -----
    loan amnt
                         396030 non-null float64
    term
                         396030 non-null object
    int rate
                         396030 non-null float64
    installment
                         396030 non-null float64
    grade
                         396030 non-null object
    sub grade
                         396030 non-null object
    emp title
                         373103 non-null object
    emp length
                         377729 non-null
                                         object
   home ownership
                         396030 non-null object
    annual inc
                         396030 non-null float64
10 verification status 396030 non-null object
11 issue d
                         396030 non-null
                                         object
 12 loan status
                         396030 non-null object
 13 purpose
                         396030 non-null object
 14 title
                         394275 non-null
                                         object
 15 dti
                         396030 non-null float64
16 earliest cr line
                         396030 non-null object
 17 open acc
                         396030 non-null float64
 18 pub rec
                         396030 non-null float64
 19 revol bal
                         396030 non-null float64
 20 revol util
                         395754 non-null float64
 21 total acc
                         396030 non-null float64
22 initial list_status 396030 non-null object
23 application type
                         396030 non-null object
 24 mort acc
                         358235 non-null float64
 25 pub rec bankruptcies 395495 non-null float64
 26 address
                         396030 non-null object
dtypes: float64(12), object(15)
memory usage: 81.6+ MB
```

Number of data is 396,030 rows

1 row = 1 transaction & information of borrower

Data types

Categorical (Object) – 15 features

Numerical (Float64) – 12 features

Total 27 features




Target variable for supervised learning

loan_status

Loan status คือ สถานะของเงินกู้

- Fully Paid : 0 คือ จ่ายครบแล้ว
- Charge Off : 1 คือ ผิดนัดชำระหนี้
 (อย่างน้อย 1 ครั้ง)

```
Fully Paid 318357
Charged Off 77673
Name: loan_status, dtype: int64
Fully Paid 0.80
Charged Off 0.20
Name: loan_status, dtype: float64
```



III LendingClub

Features selected by LightGBM

- l term
- 2 sub_grade
- 3 annual_inc
- 4 dti
- 5 mort_acc


- 6 home_ownership
- 7 int_rate
- 8 zip_code
- 9 installment

term

Term of loan คือ อายุของเงินกู้ มีอยู่ 2 ค่า ได้แก่

- 36 months (3 years) : 36
- 60 months (5 years) : 60


```
term loan_status
36 months Fully Paid 0.84
Charged Off 0.16
60 months Fully Paid 0.68
Charged Off 0.32
Name: loan_status, dtype: float64
```



sub_grade

Sub Grade คือ เกรดสินเชื่อระดับย่อย ที่ Lending Club เป็นคนกำหนด เช่น A1, A2, A3, ..., G4, G5 (G5 เป็นเกรดระดับต่ำที่สุดและ โอกาสการผิดนัดชำระหนี้สูงที่สุด)


sub_grade	loan_status	
A1	Fully Paid	0.97
	Charged Off	0.03
A2	Fully Paid	0.95
	Charged Off	0.05
A3	Fully Paid	0.94
G3	Fully Paid	0.49
G4	Fully Paid	0.55
	Charged Off	0.45
G5	Charged Off	0.50
	Fully Paid	0.50
Name: loar	_status, Lengt	th: 70, dtype: float64





III LendingClub

annual_income

Annual Income คือ รายได้ประจำปีของผู้กู้










Annual Incom	ne by Loan	Status									
	count	mean	std	min	10%	25%	50%	75%	90%	95%	max
loan_status											
Charged Off	77673.00	67535.54	58303.46	0.00	31000.00	42000.00	59000.00	80000.00	110000.00	137440.00	8706582.00
Fully Paid	318357.00	75829.95	62315.99	600.00	35000.00	46050.53	65000.00	90000.00	125000.00	150000.00	7600000.00

dti

Debt to Income Ratio คือ หนี้สินรวมต่อเดือนหารรายได้ต่อเดือน











mort_acc

Mortgage Account คือ จำนวนบัญชีที่ใช้อสังหาริมทรัพย์ ในการจำนองเพื่อขอกู้








home_ownership

Home Ownership คือ สถานะความเป็น เจ้าของบ้านที่ผู้กู้ระบุระหว่างการลงทะเบียนหรือ ได้รับจากรายงานเครดิต


- เช่า (RENT)
- เป็นเจ้าของ (OWN)
- จำนอง (MORTGAGE)
- อื่นๆ (OTHER)


home_ownership	loan_status	
MORTGAGE	Fully Paid	0.83
	Charged Off	0.17
OTHER	Fully Paid	0.84
	Charged Off	0.16
OMN	Fully Paid	0.79
	Charged Off	0.21
RENT	Fully Paid	0.77
	Charged Off	0.23
Name: loan_stat	us, dtype: flo	at64




int_rate

Interest Rate คือ อัตราดอกเบี้ยเงินกู้









Interest rat	te by Loan	Status									
	count	mean	std	min	10%	25%	50%	75%	90%	95%	max
loan_status											
Charged Off	77673.00	15.88	4.39	5.32	10.25	12.99	15.61	18.64	21.99	23.99	30.99
Fully Paid	318357.00	13.09	4.32	5.32	7.62	9.91	12.99	15.61	18.85	20.99	30.99


zip_code Zip code คือ รหัสไปรษณีย์ที่ผู้กู้ระบุในทะเบียนบ้าน (เป็นตัวแปรที่ generate ขึ้นมาใหม่จาก address)





Installment

คือ ค่างวดเงินผ่อนที่ ชำระในแต่ละงวด



2

Data Preparation


Data Cleansing
Data Transformation



Handling Numerical Variables

```
[70]: def pub rec(number):
          if number == 0.0:
              return 0
          else:
              return 1
      def mort acc(number):
          if number == 0.0:
               return 0
          elif number >= 1.0:
              return 1
          else:
              return number
      def pub rec bankruptcies(number):
          if number == 0.0:
              return 0
          elif number >= 1.0:
              return 1
          else:
               return number
[71]: data['nub_rec'] = data['nub_rec'].annlv(nub_rec)
      data['mort acc'] = data['mort acc'].apply(mort acc)
       watal pub_rec_bankruptcies j - watal pub_rec_bankruptcies
```

```
mort_acc loan_status
0.00 Fully Paid 0.76
Charged Off 0.24
1.00 Fully Paid 0.82
Charged Off 0.18
Name: loan_status, dtype: float64
```





Handling Categorical Variables

```
term

[75]: data["term"].unique()

[75]: array([' 36 months', ' 60 months'], dtype=object)

[76]: data["term"] = data["term"].map({' 36 months': 36, ' 60 months': 60})
    data["term"].sample(10)
```



Change Data type from objects to category for Feature Selections

```
def convert_obj_columns_to_category(df):
    for c in df.columns:
        col_type = df[c].dtype
        if col_type == 'object' or col_type.name == 'category':
            df[c] = df[c].astype('category')
        return df

convert_obj_columns_to_category(data)
```

```
data.info()
<class 'pandas.core.frame.DataFrame'>
Int64Index: 396030 entries, 0 to 396029
Data columns (total 22 columns):
                         Non-Null Count
   Column
                          -----
    loan amnt
                          396030 non-null float64
    term
                         396030 non-null int64
                         396030 non-null float64
    int rate
    installment
                         396030 non-null float64
                         396030 non-null category
    sub grade
   home ownership
                         396030 non-null category
   annual inc
                         396030 non-null float64
    verification status 396030 non-null category
                         396030 non-null int64
   loan status
                         396030 non-null category
    purpose
 10 dti
                         396030 non-null float64
 11 earliest cr line
                         396030 non-null int64
 12 open acc
                         396030 non-null float64
 13 pub rec
                         396030 non-null int64
 14 revol bal
                         396030 non-null float64
 15 revol util
                         396030 non-null float64
 16 total acc
                         396030 non-null float64
 17 initial list status 396030 non-null category
 18 application type
                         396030 non-null category
 19 mort acc
                         396030 non-null float64
 20 pub_rec_bankruptcies 396030 non-null float64
21 zip code
                         396030 non-null category
dtypes: category(7), float64(11), int64(4)
memory usage: 51.0 MB
```



Handling Missing Value

```
missing sumations = pd.DataFrame(data.isnull().sum(), columns=["Missing Sum"]) \
                    .sort_values(by="Missing Sum",ascending=False)
missing fractions = pd.DataFrame(data.isnull().sum(), columns=['Missing Percentage']) \
                    .apply(lambda x: round((x/data.shape[0])*100, 4), axis=1) \
                    .sort values(by="Missing Percentage" ,ascending=False)
missing tb = pd.merge(missing sumations, missing fractions, left_index=True, right_index=True)
missing tb.head(10)
                    Missing Sum Missing Percentage
                          37795
                                               9.54
          mort acc
          emp title
                          22927
                                               5.79
        emp_length
                          18301
                                               4.62
               title
                           1755
                                               0.44
pub rec bankruptcies
                            535
                                               0.14
          revol util
                            276
                                               0.07
```

```
[86]: data["mort_acc"] = data["mort_acc"].fillna(data["mort_acc"].median())
    data["revol_util"] = data["revol_util"].fillna(data["revol_util"].median())
    data["pub_rec_bankruptcies"] = data["pub_rec_bankruptcies"].fillna(data["pub_rec_bankruptcies"].median())
```

Drop Variables

ก่อนเลือก features อีกครั้ง

```
drop_list = ["grade", "emp_title", "title", "address", "issue_d", "emp_length"]
data.drop(drop_list, axis=1, inplace=True)
```

เหตุผลที่ drop variables ดังกล่าว

- grade ซ้ำกับตัวแปรอย่าง sub_grade จึงเลือกตัวที่แสดงรายละเอียดได้มากกว่าอย่าง sub_grade
- emp_title เนื่องจากเป็นตัวแปรที่มีค่าเป็นชื่ออาชีพต่าง ๆ จึงมี unique value ถึง 173,105 ตัว
- **title** แสดงรายละเอียดเกี่ยวกับว่ากู้เงินไปทำอะไร จึงมี unique value ถึง 41,327 ตัว และมีตัวแปรอย่าง purpose ที่แยกเป็นประเภทเหตุผลการกู้เงินชัดเจน สามารถใช้แทนกันได้
- address –เกี่ยวกับที่อยู่ของผู้กู้ จึงมี unique value ถึง 393,700 ตัว
- issue_d เกี่ยวกับวัน/เดือน/ปี ที่กู้เงินของ transaction ดังกล่าว *คิดว่าไม่ควรนำมาใช้ทำนาย
- emp_length เกี่ยวกับระยะเวลาการทำงานของผู้กู้ ทุกระยะเวลามีค่าแทบจะเหมือนกันจึงไม่สำคัญ

emp_length	loan_status	
1 year	0	0.80
	1	0.20
10+ years	0	0.82
	1	0.18
2 years	0	0.81
	1	0.19
3 years	0	0.80
	1	0.20
4 years	0	0.81
	1	0.19
5 years	0	0.81
	1	0.19
6 years	0	0.81
	1	0.19
7 years	0	0.81
	1	0.19
8 years	0	0.80
	1	0.20
9 years	0	0.80
	1	0.20
< 1 year	0	0.79
	1	0.21
Name: loan	status, dtype:	float64

Train Test Split [95]: # Splitting data into train and test sets train, test = train_test_split(data, test_size=0.33, random_state=42) print("Train shape is", train.shape) print("Test shape is", test.shape) Train shape is (265340, 22) Test shape is (130690, 22)

Drop Ou

Drop Outlier แค่ <u>train</u> data เพราะ <u>test</u> data จะได้คงข้อมูลจริงไว้

Outlier Handling (Outliers Detection and Removing)

Shape of Data Remaining is (265340, 22) berfore removing outlier of loan amnt is (265340, 22) after removing outlier of loan amnt is (265212, 22) -----berfore removing outlier of installment is (265212, 22) after removing outlier of installment is (261868, 22) ______ berfore removing outlier of int rate is (261868, 22) after removing outlier of int rate is (261362, 22) ______ berfore removing outlier of annual inc is (261362, 22) after removing outlier of annual inc is (258960, 22) ______ berfore removing outlier of dti is (258960, 22) after removing outlier of dti is (258954, 22) ______ berfore removing outlier of total acc is (258954, 22) after removing outlier of total acc is (256482, 22) ______ berfore removing outlier of open acc is (256482, 22) after removing outlier of open acc is (253486, 22) berfore removing outlier of revol bal is (253486, 22) after removing outlier of revol bal is (250126, 22) berfore removing outlier of revol util is (250126, 22) after removing outlier of revol util is (250119, 22) ______

result



X_tran y_train X_test y_test Split

```
[97]: X_train, y_train = train.drop('loan_status', axis=1), train.loan_status
X_test, y_test = test.drop('loan_status', axis=1), test.loan_status
```


Data Normalization



Features Selection (Features Importance)

```
'boosting type': 'gbdt',
    'num leaves': 31,
model = lgb.LGBMClassifier(**params, random state = 42) # Or use lqb.train with lqb.Dataset and train data
model.fit(X train, y train)
 feature importances = model.feature importances
 importance_lgb = pd.DataFrame({'feature': X_train.columns, 'importance': feature_importances})
 importance lgb = importance lgb.sort values(by='importance', ascending=False)
plt.figure(figsize=(10, 6))
 lgb.plot importance(model, max num features=30) # Plotting the top 10 most important features
plt.xlabel('Importance')
plt.ylabel('Feature')
plt.title('Feature Importances')
```

```
importance_lgb_list = importance_lgb["feature"][importance_lgb["importance"] > 100]
X_train = X_train[importance_lgb_list]
X_test = X_test[importance_lgb_list]
```





Encoding by One Hot Encoding (After Features Selection)

```
[102]: # dummies = list([column for column in data.columns if (data[column].dtype == "object")])
# data = pd.get_dummies(data, columns=dummies, drop_first=True)

dummies = list([column for column in X_train.columns if (X_train[column].dtype == "category")])
print(dummies)
X_train = pd.get_dummies(X_train, columns=dummies, drop_first=True)
X_test = pd.get_dummies(X_test, columns=dummies, drop_first=True)

['sub_grade', 'home_ownership', 'zip_code']
```

```
sub grade A3
                         250119 non-null uint8
   sub_grade_A4
                        250119 non-null uint8
   sub_grade_A5
                        250119 non-null uint8
                        250119 non-null uint8
10 sub_grade_B1
   sub_grade_B2
                        250119 non-null uint8
                        250119 non-null uint8
12 sub_grade_B3
                        250119 non-null uint8
   sub_grade_B4
   sub_grade_B5
                        250119 non-null uint8
15 sub_grade_C1
                        250119 non-null uint8
   sub_grade_C2
                        250119 non-null uint8
   sub_grade_C3
                        250119 non-null uint8
18 sub_grade_C4
                        250119 non-null uint8
                        250119 non-null uint8
19 sub_grade_C5
   sub grade D1
                        250119 non-null uint8
   sub_grade_D2
                        250119 non-null uint8
                        250119 non-null uint8
   sub grade D3
   sub_grade_D4
                        250119 non-null uint8
24 sub grade D5
                        250119 non-null uint8
                        250119 non-null uint8
25 sub_grade_E1
26 sub_grade_E2
                        250119 non-null uint8
                        250119 non-null uint8
27 sub_grade_E3
28 sub_grade_E4
                        250119 non-null uint8
                        250119 non-null uint8
29 sub_grade_E5
30 sub grade F1
                        250119 non-null uint8
                        250119 non-null uint8
31 sub_grade_F2
32 sub_grade_F3
                        250119 non-null uint8
                        250119 non-null uint8
33 sub_grade_F4
34 sub_grade_F5
                        250119 non-null uint8
                        250119 non-null uint8
35 sub_grade_G1
                        250119 non-null uint8
36 sub grade G2
                        250119 non-null uint8
37 sub_grade_G3
38 sub grade G4
                        250119 non-null uint8
39 sub_grade_G5
                        250119 non-null uint8
```

sub grade A2

250119 non-null uint8

```
home ownership OTHER
                       250119 non-null
                                        uint8
home ownership OWN
                       250119 non-null
                                        uint8
home ownership RENT
                       250119 non-null
                                        uint8
zip code 05113
                       250119 non-null
                                        uint8
zip code 11650
                       250119 non-null
                                        uint8
zip code 22690
                       250119 non-null
                                        uint8
zip code 29597
                       250119 non-null
                                        uint8
zip code 30723
                       250119 non-null
                                        uint8
zip code 48052
                       250119 non-null
                                        uint8
zip code 70466
                       250119 non-null
                                        uint8
zip code 86630
                       250119 non-null
                                        uint8
                       250119 non-null
zip code 93700
                                        uint8
```



การ Imbalance data จะทำพร้อมกับ train model ในคำสั่ง pipeline

ตัวอย่างของจำนวนข้อมูลหลังจาก Imbalance data

```
Imbalance (in modeling pipeline)
[139] from imblearn.over_sampling import SMOTE
      from collections import Counter
      print('Original dataset shape %s' % Counter(y train))
      rus = SMOTE(random state=0, sampling strategy=0.5)
      X_resampled, y_resampled = rus.fit_resample(X_train, y_train)
      print('Resampled dataset shape %s' % Counter(y resampled))
      Original dataset shape Counter({0: 201174, 1: 48945})
      Resampled dataset shape Counter({0: 201174, 1: 100587})
[140] from imblearn.under_sampling import RandomUnderSampler
      from collections import Counter
      print('Original dataset shape %s' % Counter(y train))
      rus = RandomUnderSampler(random state=0, sampling strategy=0.5)
      X resampled, y resampled = rus.fit resample(X train, y train)
      print('Resampled dataset shape %s' % Counter(y_resampled))
      Original dataset shape Counter({0: 201174, 1: 48945})
      Resampled dataset shape Counter({0: 97890, 1: 48945})
```

3

Modeling

by Classification Algorithm of Supervised Learning

- I. LightGBM Classifier
- 2. XGboost Classifier
- 3. Random Forest Classifier

Light Gradient
Boosting
Machine-Classifier
(LightGBM)

```
lgb_model = lgb.LGBMClassifier(objective='binary',
                               class weight='balanced')
 Define the hyperparameters for the LightGBM model
  param lgb = {
      'lightGBM_ learning_rate': [0.01, 0.05, 0.1],
      'lightGBM max_depth': [5, 10, -1],
      'lightGBM num leaves': [31, 63, 127]
 Create the pipeline with SMOTE(Over-Sampling), RandomOverSampler(Under-Sampling), and LightGBM
pipeline lgb = Pipeline([
    # ('smote', SMOTE(random state=42, sampling strategy=0.5)),
    ('under sampler', RandomUnderSampler(random state=42, sampling strategy=0.3)),
    ('lightGBM', lgb_model)
 # Create the GridSearchCV object
 grid_lgb = GridSearchCV(pipeline_lgb, param_lgb, cv=10, scoring='roc_auc', n_jobs=-1)
 Train the GridSearchCV model with Imbalance data on X train and y train
 grid_lgb.fit(X_train, y_train)
pipeline_lgb.fit(X_train, y_train)
[LightGBM] [Info] Number of positive: 100587, number of negative: 100587
[LightGBM] [Warning] Auto-choosing row-wise multi-threading, the overhead of testing was 0.004487 seconds.
You can set `force row wise=true` to remove the overhead.
And if memory is not enough, you can set `force col wise=true`.
[LightGBM] [Info] Total Bins 1620
[LightGBM] [Info] Number of data points in the train set: 201174, number of used features: 52
[LightGBM] [Info] [binary:BoostFromScore]: pavg=0.500000 -> initscore=0.000000
        Pipeline
        ► SMOTE
 ▶ RandomUnderSampler
   ▶ LGBMClassifier
```



Extreme Gradient Boosting-Classifier (XGboost)

```
Create the XGboost classifier
xgb model = xgb.XGBClassifier(objective='binary:logistic', random state=42)
 Define the hyperparameters for the XGboost model
  param_xgb = {
      'xgb n estimators': [100, 200, 300],
      'xgb_learning_rate': [0.01, 0.05, 0.1],
 Create the pipeline with SMOTE(Over-Sampling), RandomOverSampler(Under-Sampling), and XGboost
pipeline_xgb = Pipeline([
    # ('smote', SMOTE(random state=42, sampling strategy=0.5)),
    ('under_sampler', RandomUnderSampler(random_state=42, sampling_strategy=1)),
    ('xgb', xgb model),
  Create the GridSearchCV object
 grid xgb = GridSearchCV(pipeline xgb, param xgb, cv=10, scoring='roc_auc', n_jobs=-1)
 Train the GridSearchCV model with Imbalance data on X train and y train
 grid xgb.fit(X train, y train)
pipeline_xgb.fit(X_train, y_train)
        Pipeline
 ▶ RandomUnderSampler
    ▶ XGBClassifier
```



Random Forest

▶ RandomUnderSampler

▶ RandomForestClassifier

Evaluation

Evaluation Metrics

- I. Confusion Matrix
 - AccuracyF1-score
 - PrecisionRecall
- 2. ROC AUC Curve



Main Metrics



จากวัตถุประสงค์ที่ต้องการโมเดลที่ช่วยกรองผู้ที่มี "โอกาสผิดนัดช้ำระหนี้" เบื้องต้น เพื่อให้นักลงทุนใช้ในการพิจารณาเลือกผู้กู้ที่เหมาะสมแก่การลงทุนและยังช่วยลดความเสี่ยงได้


• Recall : เนื่องจากต้องการหาผู้มีโอกาสเป็น Defaulter ให้ได้มากที่สุด

• AUC score : ช่วยประเมินความสามารถของโมเดลในการแยกแยะคลาสของ

True Positive และ True Negative และเหมาะสมกับการใช้วัดความสามารถกับ

ข้อมูลที่มีลักษณะ Imbalance data

	Predicted O	Predicted 1
Actual O	TN	FP
Actual 1	FN	TP





Comparison table of 3 classification models and comparison by imbalance method

- Fully Paid		1	 Charge of 	ff	Accuracy	ALIC	Imbalance Method of VCDcoct		0 - Fully Paid		1 - Charge of		f	Λ	ALIC	Charact V. turin
recall	f1-score	precision	recall	f1-score	•	AUC	Imparance Method of AGBOOSE	precision	recall	f1-score	precision	recall	f1-score	Accuracy	AUC	Shape of Y_train
0.99	0.93	0.94	0.46	0.62	0.89	0.9048	Non-Imbalance	0.88	0.99	0.93	0.92	0.47	0.62	0.89	0.9044	({0: 201174, 1: 48945})
0.87	0.89	0.56	0.70	0.62	0.83	0.8952	Over-Sampling (SMOTE) (100%)	0.91	0.91	0.91	0.64	0.62	0.63	0.85	0.8924	({0: 201174, 1: 201174})
0.88	0.90	0.58	0.68	0.63	0.84	0.8958	Over-Sampling (SMOTE) (90%)	0.91	0.92	0.91	0.65	0.61	0.63	0.86		({0: 201174, 1: 181056})
0.91	0.91	0.64	0.64	0.64	0.86	0.8982	Over-Sampling (SMOTE) (70%)	0.90	0.94	0.92	0.69	0.58	0.63	0.87		({0: 201174, 1: 140821})
0.95	0.92	0.73	0.58	0.65	0.88	0.9012	Over-Sampling (SMOTE) (50%)	0.90	0.96	0.93	0.75	0.55	0.64	0.88		({0: 201174, 1: 140821})
0.99	0.93	0.89	0.49	0.63	0.89	0.9043	Over-Sampling (SMOTE) (30%)	0.89	0.98	0.93	0.87	0.49	0.63	0.89		({0: 201174, 1: 140821})
0.80	0.87	0.50	0.80	0.61	0.80	0.9040	Under-Sampling (RandomUnderSampler) (100%)	0.94	0.80	0.86	0.49	0.80	0.61	0.80		
0.83	0.52	0.77	0.62	0.82	0.82	0.9044	Under-Sampling (RandomUnderSampler) (90%)	0.94	0.82	0.88	0.52	0.77	0.62	0.81	0.9030	({0: 54383, 1: 48945})
0.88	0.90	0.60	0.70	0.65	0.85	0.9044	Under-Sampling (RandomUnderSampler) (70%)	0.92	0.88	0.90	0.59	0.71	0.64	0.84	0.9034	({0: 69921, 1: 48945})
0.94	0.92	0.71	0.60	0.65	0.87	0.9046	Under-Sampling (RandomUnderSampler) (50%)	0.91	0.93	0.92	0.70	0.61	0.65	0.87	0.9038	({0: 97890, 1: 48945})
0.98	0.93	0.89	0.49	0.63	0.89	0.9046	Under-Sampling (RandomUnderSampler) (30%)	0.89	0.98	0.93	0.86	0.50	0.64	0.89	0.9039	({0: 163150, 1: 48945})
0.83	0.88	0.53	0.76	0.62	0.82	0.9016	Over (50%) and then Under (100%) Sampling	0.93	0.86	0.89	0.55	0.72	0.63	0.83	0.8987	({0: 100587, 1: 100587})
				•	•											
	recall 0.99 0.87 0.88 0.91 0.95 0.99 0.80 0.83 0.88 0.94 0.98	recall f1-score 0.99 0.93 0.87 0.89 0.88 0.90 0.91 0.91 0.95 0.92 0.99 0.93 0.80 0.87 0.83 0.52 0.88 0.90 0.94 0.92 0.98 0.93	recall f1-score precision 0.99 0.93 0.94 0.87 0.89 0.56 0.88 0.90 0.58 0.91 0.91 0.64 0.95 0.92 0.73 0.99 0.93 0.89 0.80 0.87 0.50 0.83 0.52 0.77 0.88 0.90 0.60 0.94 0.92 0.71 0.98 0.93 0.89	recall f1-score precision recall 0.99 0.93 0.94 0.46 0.87 0.89 0.56 0.70 0.88 0.90 0.58 0.68 0.91 0.91 0.64 0.64 0.95 0.92 0.73 0.58 0.99 0.93 0.89 0.49 0.80 0.87 0.50 0.80 0.83 0.52 0.77 0.62 0.88 0.90 0.60 0.70 0.94 0.92 0.71 0.60 0.98 0.93 0.89 0.49	recall f1-score precision recall f1-score 0.99 0.93 0.94 0.46 0.62 0.87 0.89 0.56 0.70 0.62 0.88 0.90 0.58 0.68 0.63 0.91 0.91 0.64 0.64 0.64 0.95 0.92 0.73 0.58 0.63 0.89 0.99 0.93 0.89 0.49 0.63 0.80 0.87 0.50 0.80 0.61 0.83 0.52 0.77 0.62 0.82 0.88 0.90 0.60 0.70 0.65 0.94 0.92 0.71 0.60 0.65 0.98 0.93 0.89 0.49 0.63	recall f1-score precision recall f1-score Accuracy 0.99 0.93 0.94 0.46 0.62 0.89 0.87 0.89 0.56 0.70 0.62 0.83 0.88 0.90 0.58 0.68 0.63 0.84 0.91 0.91 0.64 0.64 0.64 0.64 0.86 0.95 0.92 0.73 0.58 0.65 0.88 0.99 0.93 0.89 0.49 0.63 0.89 0.80 0.87 0.50 0.80 0.61 0.80 0.83 0.52 0.77 0.62 0.82 0.82 0.88 0.90 0.60 0.70 0.65 0.85 0.94 0.92 0.71 0.60 0.65 0.87 0.98 0.93 0.89 0.49 0.63 0.89	recall f1-score Accuracy AUC 0.99 0.93 0.94 0.46 0.62 0.89 0.9048 0.87 0.89 0.56 0.70 0.62 0.83 0.8952 0.88 0.90 0.58 0.68 0.63 0.84 0.8958 0.91 0.91 0.64 0.64 0.64 0.86 0.8982 0.95 0.92 0.73 0.58 0.65 0.88 0.9012 0.89 0.99 0.93 0.89 0.49 0.63 0.89 0.9043 0.80 0.87 0.50 0.80 0.61 0.80 0.9040 0.83 0.52 0.77 0.62 0.82 0.82 0.9044 0.88 0.90 0.60 0.70 0.65 0.85 0.9044 0.94 0.92 0.71 0.60 0.65 0.87 0.9046 0.98 0.93 0.89 0.49 0.63 0.89 0.9	recall f1-score ACCUracy AUC Imbalance Method of XGBoost 0.99 0.93 0.94 0.46 0.62 0.89 0.9048 0.87 0.89 0.56 0.70 0.62 0.83 0.8952 0.88 0.90 0.58 0.68 0.63 0.84 0.8958 0.91 0.91 0.64 0.64 0.64 0.86 0.8982 0.95 0.92 0.73 0.58 0.65 0.88 0.9012 0.89 0.99 0.93 0.89 0.49 0.63 0.89 0.9043 0.80 0.87 0.50 0.80 0.61 0.80 0.9040 0.83 0.52 0.77 0.62 0.82 0.82 0.9044 0.88 0.90 0.60 0.70 0.65 0.85 0.9044 0.94 0.92 0.71 0.60 0.65 0.87 0.9046 0.98 0.93 0.89 0.49 0.	recall f1-score precision recall f1-score Accuracy AUC Imbalance Method of XGBoost Imba	Tecall f1-score precision recall f1-score Accuracy Auc Imbalance Method of XGBoost precision recall f1-score 0.99 0.93 0.94 0.46 0.62 0.89 0.9048 0.87 0.88 0.90 0.56 0.70 0.62 0.83 0.8952 0.88 0.90 0.58 0.68 0.63 0.84 0.8958 0.91 0.91 0.91 0.64 0.64 0.64 0.86 0.8982 0.95 0.92 0.73 0.58 0.65 0.88 0.9012 0.99 0.93 0.89 0.49 0.63 0.89 0.9043 0.83 0.52 0.77 0.62 0.82 0.82 0.9044 0.88 0.90 0.60 0.70 0.65 0.85 0.9044 0.94 0.92 0.71 0.60 0.65 0.87 0.9046 0.98 0.98 0.99 0.93 0.89 0.49 0.63 0.89 0.9046 0.904 0.90 0.905	Trickly First Fi	Precial f1-score precision recal f1-score ACCUTACY AUC Imbalance Method of XGBoost precision precision recal f1-score precision precis	Precial File File	Frecall Frecall Frecall Frecall Frecall Frecall Frecall Frecall Frecall Frecall Frecall Frecall Frecall Frecall Frecall Frecall Frecall Frecall Frecall	Frecall Frecall Frecall Frecall Frecall Frecall Frecall Frecall Frecall Frecall Frecall Frecall Frecall	Figure F

Imbalance Method of LightGBM	0	- Fully Pai	d	1	- Charge o	Accuracy	AUC	
class_weight = "balance"	precision	recall	f1-score	precision	recall	f1-score	Accuracy	AUC
Non-Imbalance	0.94	0.80	0.87	0.50	0.80	0.61	0.80	0.9049
Over-Sampling (SMOTE) (100%)	0.92	0.87	0.89	0.56	0.70	0.62	0.83	0.8952
Over-Sampling (SMOTE) (90%)	0.92	0.86	0.89	0.56	0.71	0.62	0.83	0.8960
Over-Sampling (SMOTE) (70%)	0.93	0.85	0.89	0.54	0.73	0.62	0.83	0.8986
Over-Sampling (SMOTE) (50%)	0.93	0.83	0.88	0.52	0.76	0.62	0.82	0.9014
Over-Sampling (SMOTE) (30%)	0.94	0.81	0.87	0.50	0.79	0.61	0.80	0.9042
Under-Sampling (RandomUnderSampler) (100%)	0.94	0.80	0.87	0.50	0.80	0.61	0.80	0.9040
Under-Sampling (RandomUnderSampler) (90%)	0.94	0.80	0.87	0.50	0.80	0.61	0.80	0.9043
Under-Sampling (RandomUnderSampler) (70%)	0.94	0.80	0.87	0.50	0.80	0.61	0.80	0.9046
Under-Sampling (RandomUnderSampler) (50%)	0.94	0.80	0.87	0.50	0.80	0.61	0.80	0.9048
Under-Sampling (RandomUnderSampler) (30%)	0.94	0.80	0.87	0.50	0.80	0.61	0.80	0.9050
Over (50%) and then Under (100%) Sampling	0.93	0.83	0.88	0.53	0.76	0.62	0.82	0.9016

Imbalance Method of Random Forest	0	0 - Fully Paid			1 - Charge off			AUC	Shape of Y train	
Inibalance Method of Random Porest	precision	recall	f1-score	precision	recall	f1-score	Accuracy	AUC	Shape of 1_dain	
Non-Imbalance	0.89	0.98	0.93	0.87	0.48	0.62	0.88	0.8837	({0: 201174, 1: 48945})	
Over-Sampling (SMOTE) (100%)	0.91	0.91	0.91	0.62	0.62	0.62	0.85	0.8843	({0: 201174, 1: 201174})	
Over-Sampling (SMOTE) (90%)	0.91	0.92	0.91	0.64	0.61	0.62	0.86	0.8841	({0: 201174, 1: 181056})	
Over-Sampling (SMOTE) (70%)	0.90	0.93	0.92	0.68	0.58	0.63	0.86	0.8853	({0: 201174, 1: 140821})	
Over-Sampling (SMOTE) (50%)	0.90	0.95	0.92	0.74	0.55	0.63	0.87	0.8855	({0: 201174, 1: 140821})	
Over-Sampling (SMOTE) (30%)	0.89	0.98	0.93	0.84	0.50	0.63	0.88	0.8850	({0: 201174, 1: 140821})	
Under-Sampling (RandomUnderSampler) (100%)	0.93	0.80	0.86	0.49	0.77	0.60	0.80	0.8890	({0: 48945, 1: 48945})	
Under-Sampling (RandomUnderSampler) (90%)	0.93	0.83	0.87	0.51	0.75	0.61	0.81	0.8896	({0: 54383, 1: 48945})	
Under-Sampling (RandomUnderSampler) (70%)	0.92	0.87	0.90	0.57	0.69	0.62	0.84	0.8889	({0: 69921, 1: 48945})	
Under-Sampling (RandomUnderSampler) (50%)	0.91	0.93	0.92	0.67	0.61	0.64	0.86	0.8884	({0: 97890, 1: 48945})	
Under-Sampling (RandomUnderSampler) (30%)	0.89	0.97	0.93	0.82	0.51	0.63	0.88	0.8854	({0: 163150, 1: 48945})	
Over (50%) and then Under (100%) Sampling	0.92	0.86	0.89	0.56	0.69	0.62	0.83	0.8874	({0: 100587, 1: 100587})	

เมื่อ Precision เพิ่ม Recall จะลดลงในทุกๆ กรณีดังนั้นจึงเลือก Main Metrics เป็น Recall



เลือก Model และ Imbalance Method ที่ให้ค่า Recall และ AUC สูง

		3								
Model	Imbalance Method	0 - Fully Paid			1 - Charge off			Accuracy	AUC	Shape of Y_train
Model	Inibalance Method	precision	recall	f1-score	precision	recall	f1-score	Accuracy	AUC	Shape of T_train
LightGBM - classweight = "None"	Under-Sampling (RandomUnderSampler) (100%)	0.94	0.80	0.87	0.50	0.80	0.61	0.80	0.9040	({0: 48945, 1: 48945})
LightGBM - classweight = "balanced"	Under-Sampling (RandomUnderSampler) (30%)	0.94	0.80	0.87	0.50	0.80	0.61	0.80	0.9050	({0: 163150, 1: 48945})
XGboost	Under-Sampling (RandomUnderSampler) (100%)	0.94	0.80	0.86	0.49	0.80	0.61	0.80	0.9026	({0: 48945, 1: 48945})
Random forest	Under-Sampling (RandomUnderSampler) (100%)	0.93	0.80	0.86	0.49	0.77	0.60	0.80	0.8890	({0: 48945, 1: 48945})

Best Model


Model: LightGBM - class_weight = "balanced"

Imbalance Method: RandomUnderSampler - sampling_strategy = 0.3

Charge-Off Recall = 0.80 AUC score = 0.9050



Best Model Evaluation Metrics




Classification	n Report of 1	Train Data	a:	
	precision	recall	f1-score	support
0	0.95	0.81	0.87	201174
1	0.51	0.82	0.63	48945
accuracy			0.81	250119
macro avg	0.73	0.81	0.75	250119
weighted avg	0.86	0.81	0.82	250119

Classificatio	n Report of 1 precision		: f1-score	support
0 1	0.94 0.50	0.80 0.80	0.87 0.61	104951 25739
accuracy macro avg weighted avg	0.72 0.85	0.80 0.80	0.80 0.74 0.82	130690 130690 130690



Best Model Evaluation Metrics

```
# auc_score_lgb = roc_auc_score(y_test, best_model_lgb.predict_proba(X_test)[:, 1])
# print(f"AUC Score: {auc_score_lgb:.4f}")
auc_score_lgb = roc_auc_score(y_test, pipeline_lgb.predict_proba(X_test)[:, 1])
print(f"AUC Score: {auc_score_lgb:.4f}")
AUC Score: 0.9050
```



Features Importance 9 features

- I. Term
- 2. Sub grade
- 3. Annual income
- 4. Debt to income
- 5. Mortgage Account
- 6. Home ownership
- 7. Interest rate
- 8. Zip code
- 9. Installment

หลังจากการ EDA ข้อมูลก็เห็นได้ชัด ว่าส่งผลต่อการผิดนัดชำระหนี้

Conclusion

ได้ Model ที่ตรงตามวัตถุประสงค์ คือ

Model: Light Gradient Boosting Machine-Classifier

- Charge-Off Recall = 0.80
- AUC score = 0.9050

- เข้าใจเกี่ยวกับลักษณะการกู้เงินแบบ P2P
- ได้เรียนรู้เทคนิคและวิธีการ EDA
- ได้เรียนขั้นตอนและเครื่องมือต่างๆ ที่สำคัญในการเตรียมข้อมูล

